

UNIVERSIDADE ESTADUAL DE CAMPINAS

Séries Temporais

Modelo Prophet para Séries Temporais: Teoria, Ilustração e Discussão Crítica

Projeto 1 — Modelo Teórico

Nome: Arthur Lourenço Narcizo da Silva

RA: 236043

Campinas, 15 de abril de 2026

Sumário

1	Introdução	2
2	Formulação Teórica	2
2.1	Decomposição	2
2.2	Tendência com <i>changepoints</i>	2
2.3	Sazonalidade (Fourier)	3
2.4	Feriados	3
2.5	Estimação	3
2.6	Comparação com ARIMA	3
3	Ilustração: Produção Industrial Brasileira	4
3.1	Dados	4
3.2	Configuração	5
3.3	Componentes	6
3.4	Resultados	7
3.5	Benchmarks	8
3.6	Validação cruzada	8
3.7	Diagnósticos dos resíduos	9
4	Discussão Crítica	11
4.1	Vantagens	11
4.2	Desvantagens	11
4.3	Limitações nesta série	11
4.4	Como melhorar	12
5	Conclusão	12
	Referências	14

1 Introdução

O modelo Prophet, proposto por Taylor e Letham [5], é um modelo aditivo generalizado para séries temporais com tendência, sazonalidade e feriados, estimado via inferência bayesiana. Diferentemente da abordagem clássica de Box-Jenkins [6], amplamente discutida por Morettin e Toloi [2], o Prophet não requer estacionariedade da série e adota uma estrutura de decomposição com priors bayesianos, o que o situa fora do conteúdo programático tradicional de modelos ARIMA.

Este relatório apresenta: (i) a formulação matemática do Prophet, (ii) uma ilustração com o índice de produção industrial brasileiro (IBGE, Série 21859 do BCB) [11], e (iii) discussão crítica do modelo aplicado a esses dados.

2 Formulação Teórica

2.1 Decomposição

O Prophet decompõe $y(t)$ em componentes interpretáveis [5]:

$$y(t) = g(t) + s(t) + h(t) + \varepsilon_t, \quad \varepsilon_t \sim \mathcal{N}(0, \sigma^2) \quad (1)$$

onde $g(t)$ é a tendência, $s(t)$ a sazonalidade e $h(t)$ feriados. No modo multiplicativo: $y(t) = g(t)(1 + s(t)) + h(t) + \varepsilon_t$. Essa decomposição é análoga à dos modelos estruturais de Harvey [7], porém com parametrização distinta voltada à flexibilidade e ao uso em escala.

2.2 Tendência com *changepoints*

$$g(t) = (k + \mathbf{a}(t)^\top \boldsymbol{\delta}) t + (m + \mathbf{a}(t)^\top \boldsymbol{\gamma}) \quad (2)$$

onde k é a taxa base, m o intercepto, $a_j(t) = \mathbf{1}[t \geq s_j]$, δ_j ajusta a taxa no *changepoint* s_j , e $\gamma_j = -s_j \delta_j$ garante continuidade. O prior regularizador é:

$$\delta_j \sim \text{Laplace}(0, \tau) \quad (3)$$

com τ (`changepoint_prior_scale`) controlando a flexibilidade da tendência [5]. A distribuição Laplace favorece esparsidade, fazendo com que a maioria dos δ_j seja próxima de zero, e apenas os *changepoints* mais relevantes tenham ajustes significativos.

2.3 Sazonalidade (Fourier)

$$s(t) = \sum_{n=1}^N \left(a_n \cos \frac{2\pi n t}{P} + b_n \sin \frac{2\pi n t}{P} \right), \quad \boldsymbol{\beta} \sim \mathcal{N}(\mathbf{0}, \sigma_s^2 \mathbf{I}) \quad (4)$$

com período P e ordem N . O prior σ_s (`seasonality_prior_scale`) controla a amplitude. A representação por séries de Fourier para sazonalidade é discutida em Hyndman e Athanasopoulos [9].

2.4 Feriados

$h(t) = \sum_i \kappa_i \cdot \mathbf{1}[t \in D_i]$, com $\kappa_i \sim \mathcal{N}(0, \nu^2)$. Essa componente permite modelar eventos que não seguem periodicidade fixa, como o Carnaval no Brasil, cuja data varia a cada ano.

2.5 Estimação

Os parâmetros são estimados via MAP usando L-BFGS no *backend* Stan [8]:

$$\hat{\boldsymbol{\theta}} = \arg \max_{\boldsymbol{\theta}} [\log p(\mathbf{y}|\boldsymbol{\theta}) + \log p(\boldsymbol{\theta})] \quad (5)$$

Intervalos de confiança são gerados por simulação da incerteza em $\boldsymbol{\delta}$, $\boldsymbol{\beta}$ e ε_t .

2.6 Comparação com ARIMA

A metodologia clássica de Box-Jenkins [6], descrita em detalhes por Morettin e Toloi [2], requer estacionariedade da série para identificação do modelo ARIMA. O Prophet adota uma abordagem diferente, conforme a Tabela 1.

Tabela 1: Prophet vs. modelos do conteúdo programático.

Aspecto	ARIMA	Prophet
Abordagem	Box-Jenkins	GAM bayesiano
Estacionariedade	Requer	Não requer
Sazonalidade	$(P, D, Q)_s$	Fourier
Tendência	Diferenciação	Changepoints
ICs	Analíticos	Simulação
Estimação	MLE	MAP (Stan)

3 Ilustração: Produção Industrial Brasileira

3.1 Dados

A série utilizada é o Índice de Produção Industrial (base = 100), calculado pelo IBGE na Pesquisa Industrial Mensal — Produção Física (PIM-PF) [11], disponibilizado pelo Banco Central do Brasil (Série 21859 do SGS). Os dados foram obtidos via API do BCB, abrangendo o período de janeiro de 2002 a janeiro de 2026, totalizando 289 observações mensais.

A série reflete o nível de atividade da indústria brasileira e apresenta tendência, sazonalidade (queda em janeiro/fevereiro e dezembro por férias coletivas) e choques estruturais (crise de 2008, recessão 2015–2016, COVID-19 em 2020).



Figura 1: Produção Industrial — Brasil (IBGE, Série 21859 BCB).

A decomposição STL (Figura 2) confirma a presença de tendência e sazonalidade. A força da tendência é $F_t = 0,85$ e a força da sazonalidade é $F_s = 0,82$, ambas elevadas, calculadas conforme Hyndman e Athanasopoulos [9]. O teste ADF indica não estacionariedade em nível ($p = 0,17$) e estacionariedade na primeira diferença ($p = 0,0001$), o que é esperado para uma série com tendência. A não estacionariedade justifica a diferenciação nos modelos ARIMA clássicos [2], enquanto o Prophet lida com essa característica diretamente via *changepoints*.




Figura 2: Decomposição STL.




Figura 3: Sazonalidade mensal — queda em jan., fev. e dez.

3.2 Configuração

O modelo foi configurado com tendência linear, *changeoints* automáticos ($\tau = 0,1$, *changeoint_range* = 0.85), sazonalidade aditiva via série de Fourier com $N = 8$ termos

($\sigma_s = 10$), e o Carnaval como feriado. O intervalo de confiança foi fixado em 95%. Os dados foram divididos temporalmente em 80% para treino (231 obs., jan/2002 a mar/2021) e 20% para teste (58 obs., abr/2021 a jan/2026). O modelo detectou 25 *changepoints* automaticamente.

Tabela 2: Hiperparâmetros do Prophet.

Tendência	Linear, changepoints automáticos (25 detectados)
<code>changepoint_prior_scale</code>	0.1
<code>changepoint_range</code>	0.85
Sazonalidade	Aditiva, Fourier $N = 8$
<code>seasonality_prior_scale</code>	10.0
Feriados	Carnaval (afeta produção em fev./mar.)
IC	95%
Divisão	80%/20% temporal (231/58 obs.)

3.3 Componentes




Figura 4: Componentes estimados pelo Prophet.




Figura 5: Changepoints na tendência.

3.4 Resultados




Figura 6: Real vs. Prophet (teste) com IC 95%.

O modelo obteve RMSE de 4.67, MAE de 3.91, MAPE de 3.79% e $R^2 = 0,57$ no conjunto de teste. O coeficiente U de Theil foi de 0.0233, e a cobertura do intervalo de confiança de 95% foi de 100%, indicando que todos os valores reais ficaram dentro da faixa prevista. Segundo a classificação de Lewis [10], um MAPE abaixo de 10% indica previsão de alta acurácia.

Tabela 3: Métricas de desempenho.

RMSE	4.67
MAE	3.91
MAPE	3.79%
R^2	0.5731
U de Theil	0.0233
Cobertura IC 95%	100.0%

3.5 Benchmarks

Para avaliar se o Prophet agrega valor em relação a métodos triviais, foram calculadas as métricas para quatro benchmarks clássicos [9]. O Naïve prevê o valor do mês anterior ($\hat{y}_{t+1} = y_t$); o Sazonal-Naïve usa o valor do mesmo mês do ano anterior ($\hat{y}_{t+1} = y_{t-12}$); a Média prevê a média dos valores observados no teste; e o Drift projeta uma reta entre o primeiro e o último valor do treino.

Tabela 4: Comparação com benchmarks.

Modelo	RMSE	MAE	MAPE
Prophet	4.67	3.91	3.79%
Naïve	5.62	4.51	4.46%
S-Naïve	2.53	1.81	1.76%
Média	7.15	6.04	6.01%
Drift	7.05	5.97	5.98%




Figura 7: MAPE: Prophet vs. benchmarks.

O Prophet superou os benchmarks Naïve, Média e Drift, porém o Sazonal-Naïve obteve MAPE inferior (1.76% vs. 3.79%). Esse resultado indica que, no período recente, a sazonalidade é o componente dominante da série, e a tendência estimada pelo Prophet acaba introduzindo mais erro do que benefício.

3.6 Validação cruzada

A validação cruzada temporal foi realizada com janela inicial de 1460 dias (aproximadamente 4 anos), período entre janelas de 365 dias e horizonte de previsão de 365 dias, seguindo a metodologia descrita em Hyndman e Athanasopoulos [9]. O MAPE médio

obtido foi de 4.88% e o RMSE médio de 6.84, valores coerentes com o desempenho no teste.




Figura 8: MAPE por horizonte (validação cruzada temporal).

3.7 Diagnósticos dos resíduos

Os resíduos ($e_t = y_t - \hat{y}_t$) foram analisados por meio de quatro testes estatísticos ao nível de significância de 5%, conforme recomendado na literatura de análise de séries temporais [2, 4].




Figura 9: Diagnósticos: resíduos, histograma, QQ-Plot, ACF.

Tabela 5: Testes dos resíduos ($\alpha = 5\%$).

Teste	H_0	p-valor	Decisão
Jarque-Bera	Normalidade	0.7003	Não rejeita H_0 (Normal)
Ljung-Box (12)	Sem autocorrelação	< 0.0001	Rejeita H_0 (Autocorrelação)
Teste t	Média = 0	< 0.0001	Rejeita H_0 (Viés)
Spearman	Homocedasticidade	< 0.0001	Rejeita H_0 (Heterocedasticidade)

O teste de Jarque-Bera não rejeitou a hipótese de normalidade ($p = 0,70$), o que significa que a distribuição dos resíduos é aproximadamente gaussiana. Entretanto, os demais testes apontaram problemas. O teste t rejeitou a hipótese de média zero ($p < 0,0001$), com média dos resíduos de 3.47, revelando um viés sistemático positivo — o Prophet subestima a produção industrial no período de teste. O teste de Ljung-Box rejeitou a hipótese de ausência de autocorrelação em todos os lags testados ($p < 0,0001$), confirmando que os erros possuem dependência temporal que o modelo não captura. Por fim, o teste de Spearman entre $|e_t|$ e t resultou em $\rho = 0,69$ ($p < 0,0001$), indicando heterocedasticidade — os erros tendem a crescer ao longo do horizonte de previsão.

4 Discussão Crítica

4.1 Vantagens

A principal vantagem do Prophet é a decomposição interpretável: tendência, sazonalidade e feriados são estimados e visualizados separadamente, permitindo ao analista entender o que impulsiona a previsão [5]. Além disso, o modelo identifica *changepoints* automaticamente — nesta aplicação, foram detectados 25 pontos de mudança que capturam eventos como a crise de 2008, a recessão de 2015 e o choque da COVID-19, sem intervenção manual.

Outra vantagem é que o Prophet não requer estacionariedade. Enquanto a metodologia ARIMA de Box-Jenkins [6] exige diferenciação para estabilizar a série (o teste ADF indicou não estacionariedade em nível, $p = 0,17$), o Prophet lida com a tendência diretamente via *changepoints*. O modelo também é robusto a dados faltantes e gera intervalos de confiança nativos por simulação bayesiana, que nesta aplicação atingiram cobertura de 100%. A inclusão do Carnaval como feriado é outro ponto positivo, já que esse evento afeta diretamente a produção industrial em fevereiro e março.

4.2 Desvantagens

A desvantagem mais relevante, confirmada pelos diagnósticos, é que o Prophet não modela a autocorrelação residual. O termo ε_t é tratado como i.i.d., o que o teste de Ljung-Box mostrou ser inadequado ($p < 0,0001$ em todos os lags). Em contraste, modelos ARIMA capturam essa dependência por meio dos termos AR e MA [2].

Os diagnósticos também revelaram viés sistemático: a média dos resíduos é 3.47, o que significa que o Prophet subestima a produção industrial no período de teste. Esse viés se deve à tendência linear, que projeta a queda de 2020 para frente, sem capturar adequadamente a recuperação pós-COVID. A heterocedasticidade detectada pelo teste de Spearman ($\rho = 0,69$) reforça que os erros crescem com o horizonte.

Outras desvantagens incluem a sazonalidade fixa — os coeficientes de Fourier não mudam ao longo do tempo, o que prejudica séries com sazonalidade evolutiva — e a extrapolação linear da tendência, que pode divergir em horizontes longos. A escolha entre modo aditivo e multiplicativo também é manual e pode impactar significativamente os resultados.

4.3 Limitações nesta série

A produção industrial brasileira é uma série particularmente desafiadora para o Prophet. Os choques extremos, como a queda de aproximadamente 25% em abril de 2020 pela

COVID-19, são tratados como ruído pelo modelo, e não como eventos estruturados. A tendência é irregular — crescimento até 2013, estagnação entre 2014 e 2019, choque em 2020 e recuperação posterior —, exigindo muitos *changepoints* e aumentando o risco de sobreajuste.

O $R^2 = 0,57$ no teste mostra que o modelo explica pouco mais da metade da variabilidade. O fato de o Sazonal-Naïve ter superado o Prophet em todas as métricas (MAPE de 1.76% contra 3.79%) sugere que, para esta série no período recente, a sazonalidade é tão dominante que basta repetir o padrão do ano anterior para obter previsões melhores do que as do Prophet [9]. Isso indica que a tendência estimada pelo modelo introduz mais erro do que benefício.

4.4 Como melhorar

Uma melhoria direta seria modelar a COVID-19 como feriado usando os parâmetros `lower_window` e `upper_window` [5], o que permitiria ao Prophet tratar o choque como evento especial em vez de ruído. A inclusão de regressores externos — como taxa SELIC, taxa de câmbio ou o Índice de Confiança da Indústria da FGV — também poderia melhorar as previsões, aproveitando a capacidade do Prophet de incorporar variáveis exógenas.

Outra abordagem seria otimizar os hiperparâmetros τ e σ_s via *grid search* com validação cruzada, em vez de usar valores fixos. Um modelo híbrido que combine Prophet com ARIMA nos resíduos poderia capturar a autocorrelação residual detectada pelo teste de Ljung-Box, seguindo a abordagem discutida por Shumway e Stoffer [4]. A modelagem de séries com comportamento não-linear, como discutido por Morettin e Toloi [3], também poderia ser explorada para capturar a dinâmica irregular da produção industrial. Por fim, substituir a tendência linear por uma tendência logística com capacidade de saturação evitaria a divergência da extrapolação em horizontes longos.

5 Conclusão

O Prophet decompõe séries temporais em tendência com *changepoints* bayesianos, sazonalidade via séries de Fourier e feriados, estimados via MAP [5]. Na ilustração com a produção industrial brasileira (IBGE, Série 21859, jan/2002 a jan/2026, 289 observações) [11], o modelo capturou os padrões sazonais e as mudanças de tendência, obtendo MAPE de 3.79% no teste e 4.88% na validação cruzada, com cobertura de 100% do intervalo de confiança.

Contudo, os diagnósticos revelaram limitações importantes. Embora os resíduos sigam distribuição normal (Jarque-Bera, $p = 0,70$), foi detectado viés sistemático (média = 3,47, $p < 0,0001$), autocorrelação significativa (Ljung-Box, $p < 0,0001$) e heterocedasticidade

(Spearman, $\rho = 0,69$). O $R^2 = 0,57$ indica poder explicativo moderado, e o Sazonal-Naïve superou o Prophet em todas as métricas.

Esses resultados confirmam que a principal fraqueza do Prophet é não modelar a autocorrelação residual, tratando ε_t como i.i.d. Melhorias possíveis incluem modelo híbrido Prophet+ARIMA [4], COVID-19 como evento especial, regressores externos e tendência logística. Ainda assim, o modelo superou os benchmarks Naïve, Média e Drift [9], e sua principal contribuição permanece na interpretabilidade dos componentes e na facilidade de uso para previsões rápidas em contexto aplicado.

Referências

Referências

- [1] MORETTIN, P. A.; TOLOI, C. M. C. *Análise de Séries Temporais*. 2.^a ed. ABE — Projeto Fisher. Blucher, São Paulo, 2006. ISBN: 978-85-212-0389-6.
- [2] MORETTIN, P. A.; TOLOI, C. M. C. *Análise de Séries Temporais, Volume 1: Modelos Lineares Univariados*. 3.^a ed. ABE — Projeto Fisher. Blucher, São Paulo, 2018. ISBN: 978-85-212-1349-9.
- [3] MORETTIN, P. A.; TOLOI, C. M. C. *Análise de Séries Temporais, Volume 2: Modelos Multivariados e Não-Lineares*. ABE — Projeto Fisher. Blucher, São Paulo, 2020. ISBN: 978-85-212-1626-1.
- [4] SHUMWAY, R. H.; STOFFER, D. S. *Time Series Analysis and Its Applications*. 4th ed. Springer, Nova Iorque, 2017. ISBN: 978-3-319-52451-1.
- [5] TAYLOR, S. J.; LETHAM, B. Forecasting at scale. *The American Statistician*, v. 72, n. 1, p. 37–45, 2018. ISSN: 0003-1305.
- [6] BOX, G. E. P.; JENKINS, G. M.; REINSEL, G. C.; LJUNG, G. M. *Time Series Analysis: Forecasting and Control*. 5th ed. Wiley, 2015. ISBN: 978-1-118-67502-1.
- [7] HARVEY, A. C.; SHEPHARD, N. Structural time series models. In: *Handbook of Statistics*, v. 11. Elsevier, 1993. ISBN: 978-0-444-89572-2.
- [8] CARPENTER, B. et al. Stan: A probabilistic programming language. *Journal of Statistical Software*, v. 76, n. 1, 2017. ISSN: 1548-7660.
- [9] HYNDMAN, R. J.; ATHANASOPOULOS, G. *Forecasting: Principles and Practice*. 3rd ed. OTexts, 2021. ISBN: 978-0-9875071-3-6.
- [10] LEWIS, C. D. *Industrial and Business Forecasting Methods*. Butterworth-Heinemann, 1982. ISBN: 978-0-408-00532-2.
- [11] IBGE. Pesquisa Industrial Mensal — Produção Física (PIM-PF). Disponível em: <https://www.ibge.gov.br/estatisticas/economicas/industria/9294-pesquisa-industrial-mensal-producao-fisica-brasil.html>. Acesso em: mar. 2026.