

UNIVERSIDADE ESTADUAL DE CAMPINAS

Séries Temporais — ME607

Modelagem da Volatilidade e Análise de Intervenção
em Retornos da Petrobras (PETR4):
Impactos de Eventos Político-Econômicos no Período
2010–2026

Projeto 2 — Análise de Dados

Nome: Arthur Lourenço Narcizo da Silva

RA: 236043

Campinas, 19 de maio de 2026

Sumário

Resumo	3
1 Introdução	4
2 Referencial Teórico	5
2.1 Fatos estilizados de séries financeiras	5
2.2 Log-retornos	5
2.3 Modelos ARMA	5
2.4 Modelos GARCH e EGARCH	5
2.5 Distribuição t -Student padronizada	6
2.6 Análise de intervenção	6
2.7 Value-at-Risk e backtesting	7
3 Metodologia	7
3.1 Dados	7
3.2 Eventos selecionados para análise de intervenção	7
3.3 Software e reprodutibilidade	8
4 Análise Descritiva e Exploratória	8
4.1 Estatísticas resumo	8
4.2 Visualização da série	8
4.3 Distribuição dos retornos	9
4.4 Testes de hipótese	10
4.5 Funções de autocorrelação	10
5 Construção do Modelo ARMA-GARCH	11
5.1 Modelos candidatos e seleção	11
5.2 Estimativas do modelo final	12
6 Análise de Intervenção	13
7 Diagnóstico do Modelo	13

7.1	Análise gráfica dos resíduos	13
7.2	Volatilidade condicional	14
8	Estimação do Value-at-Risk e Backtesting	15
9	Discussão Crítica	16
10	Conclusão	17

Resumo

Modelei os log-retornos diários da PETR4 entre 04/01/2010 e 29/04/2026, num total de 4053 observações, usando a família ARMA-GARCH. A análise descritiva mostrou caudas pesadas (curtose em excesso de 13,35), assimetria negativa de $-0,93$ e forte heterocedasticidade condicional, com o teste ARCH-LM rejeitando homocedasticidade a p -valor inferior a 10^{-130} . Estimei três modelos por máxima verossimilhança: GARCH(1,1)- t , EGARCH(1,1)- t e EGARCH(1,1)- t com regressores de intervenção para eventos político-econômicos.

O modelo final, escolhido pelo menor AIC, capturou efeito alavancagem significativo ($\gamma = -0,030$, $p < 0,001$) e estimou impacto pontual de $-6,50$ pontos percentuais no retorno do dia da demissão de Castello Branco. Calculei o Value-at-Risk paramétrico nos níveis de 95% e 99% e o teste de Kupiec não rejeitou a adequação do modelo a 99% ($p = 0,488$), o que permite usar o modelo para gestão de risco de mercado.

Palavras-chave: séries temporais financeiras; GARCH; EGARCH; análise de intervenção; Value-at-Risk; PETR4.

1 Introdução

A modelagem de séries temporais financeiras é uma das áreas mais desenvolvidas e aplicadas da econometria moderna, em razão de sua relevância para gestão de risco, precificação de derivativos e alocação de portfólios. Séries de retornos exibem propriedades estatísticas peculiares, conhecidas na literatura como fatos estilizados, que tornam inadequada a aplicação direta de modelos clássicos baseados em homocedasticidade e normalidade [1].

A ação preferencial da Petrobras é um caso emblemático no mercado brasileiro. Por sua liquidez, peso no Ibovespa e exposição a riscos políticos, regulatórios e geopolíticos, a série de retornos apresenta clusters de volatilidade pronunciados e várias quebras estruturais associadas a eventos discretos — crises de governança, mudanças de comando, alterações na política de preços de combustíveis. Estudar esses fenômenos com modelos rigorosos tem interesse acadêmico e prático.

O objetivo deste trabalho é construir um modelo estatístico para a média e a volatilidade condicionais dos log-retornos diários da PETR4 no período 2010–2026, capaz de capturar os fatos estilizados das séries financeiras e de quantificar o impacto de eventos político-econômicos. Como objetivos específicos, busco realizar análises descritiva, exploratória e inferencial dos retornos; identificar e estimar modelos da família GARCH com diagnósticos formais; mensurar o efeito de eventos relevantes via análise de intervenção; e calcular o Value-at-Risk diário com posterior validação por backtesting.

A escolha da PETR4 não é arbitrária. Quis um ativo brasileiro com histórico longo, episódios de stress bem documentados e relevância prática para o mercado local — e PETR4 cumpre as três condições com folga.¹

O texto está organizado da seguinte forma. A Seção 2 apresenta o referencial teórico, com ênfase nos modelos GARCH e EGARCH, na análise de intervenção e no Value-at-Risk. A Seção 3 detalha a metodologia, os dados e o software utilizado. A Seção 4 traz a análise descritiva. A Seção 5 documenta a estimação e a seleção do modelo final. A Seção 6 é dedicada à análise de intervenção. A Seção 7 apresenta os diagnósticos. A Seção 8 calcula o VaR e o submete a backtesting. A Seção 9 traz a discussão crítica e a Seção 10 conclui.

¹Cheguei a considerar VALE3 e ITUB4, mas a riqueza dos eventos políticos sobre a Petrobras tornou a análise de intervenção mais informativa.

2 Referencial Teórico

2.1 Fatos estilizados de séries financeiras

A literatura empírica em finanças, discutida em Morettin [1] e em Shumway e Stoffer [4], documenta propriedades recorrentes em séries de retornos. Entre as principais, destacam-se a ausência de autocorrelação linear nos retornos, contrastada pela autocorrelação significativa nos retornos ao quadrado — o que indica dependência não linear. Há também evidência empírica robusta de caudas mais pesadas que as da normal (leptocurtose) e de clusters de volatilidade, em que períodos de oscilações grandes tendem a ser seguidos por mais oscilações grandes. Observa-se ainda o efeito alavancagem: assimetria entre choques positivos e negativos sobre a variância futura.

2.2 Log-retornos

Seja P_t o preço de um ativo no instante t . Define-se o log-retorno em percentual como

$$r_t = 100 \cdot \ln\left(\frac{P_t}{P_{t-1}}\right), \quad (1)$$

medida preferida em finanças por sua aditividade temporal e por aproximar-se da distribuição normal sob agregação, conforme discutido em Morettin [1].

2.3 Modelos ARMA

Um processo $\{r_t\}$ segue um modelo ARMA(p, q) se

$$\phi(B) r_t = \theta(B) a_t, \quad (2)$$

onde B é o operador de retardo, $\phi(B) = 1 - \phi_1 B - \dots - \phi_p B^p$, $\theta(B) = 1 + \theta_1 B + \dots + \theta_q B^q$ e $\{a_t\}$ é ruído branco com $\mathbb{E}(a_t) = 0$ e $\text{Var}(a_t) = \sigma_a^2$. A metodologia de identificação, estimação e diagnóstico segue o roteiro clássico de Box e Jenkins, descrito em detalhe em Morettin e Toloi [2].

2.4 Modelos GARCH e EGARCH

Engle [5] propôs o modelo ARCH(q) para descrever a heterocedasticidade condicional observada em séries financeiras — trabalho seminal que lhe rendeu o Prêmio Nobel de

Economia em 2003. Bollerslev [6] estendeu a formulação para o GARCH(p, q):

$$a_t = \sigma_t \varepsilon_t, \quad \sigma_t^2 = \omega + \sum_{i=1}^q \alpha_i a_{t-i}^2 + \sum_{j=1}^p \beta_j \sigma_{t-j}^2, \quad (3)$$

com $\omega > 0$, $\alpha_i, \beta_j \geq 0$ e $\sum(\alpha_i + \beta_j) < 1$ como condição de estacionariedade da variância.

Uma limitação conhecida do GARCH é tratar de forma simétrica choques positivos e negativos. Para contornar isso, Nelson [7] propôs o EGARCH(p, q), definido sobre o logaritmo da variância:

$$\ln \sigma_t^2 = \omega + \sum_{i=1}^q [\alpha_i |\varepsilon_{t-i}| + \gamma_i \varepsilon_{t-i}] + \sum_{j=1}^p \beta_j \ln \sigma_{t-j}^2. \quad (4)$$

Quando o coeficiente γ é negativo e significativo, há evidência de efeito alavancagem: choques negativos elevam a volatilidade futura mais do que choques positivos de mesma magnitude. Outra vantagem do EGARCH é dispensar restrições de positividade sobre os coeficientes, já que modela diretamente o logaritmo da variância.

2.5 Distribuição t -Student padronizada

Dada a leptocurtose dos retornos financeiros, é prática estabelecida adotar inovações $\varepsilon_t \sim t_\nu$ padronizada, com variância unitária e $\nu > 2$ graus de liberdade. Quanto menor o valor de ν , mais pesadas são as caudas. No limite $\nu \rightarrow \infty$, recupera-se a normal padrão.

2.6 Análise de intervenção

A análise de intervenção, discutida em Morettin e Tolo [3], propõe incluir variáveis indicadoras na equação da média para modelar o impacto de eventos discretos sobre a série. As duas formas básicas de função de intervenção são o pulso e o degrau. No pulso, a indicadora I_t assume valor unitário apenas no instante do evento $t = T^*$, capturando um efeito transitório de um único período. No degrau, a indicadora assume valor unitário a partir do evento — isto é, para todo $t \geq T^*$ —, capturando um efeito permanente sobre o nível da série. A média condicional fica então $\mu_t = c + \phi_1 r_{t-1} + \sum_k \delta_k I_{k,t}$, onde δ_k representa o efeito do k -ésimo evento.

2.7 Value-at-Risk e backtesting

O Value-at-Risk no nível α é o quantil- α da distribuição condicional de perdas:

$$\text{VaR}_t(\alpha) = -(\mu_t + q_\alpha(\nu) \cdot \sigma_t), \quad (5)$$

onde $q_\alpha(\nu)$ é o quantil- α da t -Student padronizada [1]. Para validar o modelo, usa-se o teste de cobertura incondicional de Kupiec, baseado na razão de verossimilhança

$$\text{LR}_{uc} = -2 \ln \left[\frac{(1 - \alpha)^{n-x} \alpha^x}{(1 - \hat{p})^{n-x} \hat{p}^x} \right] \sim \chi_1^2, \quad (6)$$

em que x é o número de violações observadas, n o tamanho amostral e $\hat{p} = x/n$ a taxa empírica de violações. Sob a hipótese nula de cobertura correta, a estatística segue qui-quadrado com um grau de liberdade.

3 Metodologia

3.1 Dados

Coleti preços de fechamento ajustados diários da PETR4 entre 04/01/2010 e 29/04/2026, totalizando 4054 pregões e 4053 log-retornos. A fonte primária foi o Yahoo Finance, e os dados foram consolidados em arquivo CSV hospedado em repositório público no GitHub: https://github.com/arthurncarizo/S-ries_Temporais_ME607. Isso garante reprodutibilidade plena dos resultados. O preço utilizado já incorpora ajustes por proventos e desdobramentos.²

3.2 Eventos selecionados para análise de intervenção

Após levantamento da imprensa especializada e do histórico de preços do ativo, selecionei três eventos com elevada repercussão e impacto observável (Tabela 1).

Tabela 1: Eventos político-econômicos modelados por intervenção.

Evento	Data	Tipo de dummy
Demissão de Roberto Castello Branco	19/02/2021	Pulso
Mudança da política de preços (gov. Lula)	08/03/2023	Degrau
Demissão de Jean Paul Prates	14/05/2024	Pulso

²Inicialmente tentei coletar os dados diretamente pela API do BCB, mas a série não cobria o período completo. O Yahoo Finance, ainda que com limitações conhecidas, foi a opção mais prática.

3.3 Software e reprodutibilidade

A análise foi conduzida em Python 3.11 com as bibliotecas `pandas`, `numpy`, `scipy`, `statsmodels` e `arch` [8]. O código-fonte é fornecido como arquivo suplementar e a semente aleatória foi fixada em 42 para garantir resultados idênticos em execuções futuras. O fluxograma do método é apresentado em arquivo suplementar e segue o roteiro Box-Jenkins adaptado à modelagem da volatilidade condicional, com as etapas de identificação, estimação, diagnóstico, previsão (VaR) e backtesting.

4 Análise Descritiva e Exploratória

4.1 Estatísticas resumo

A Tabela 2 apresenta as estatísticas descritivas dos log-retornos. A média é próxima de zero (0,0447% ao dia) e o desvio-padrão é alto, 2,74%, equivalente a cerca de 43,4% de volatilidade anualizada³. A assimetria negativa de $-0,93$ indica preponderância de retornos extremos no lado das perdas, e a curtose em excesso de 13,35 revela caudas muito mais pesadas que as da normal. Esses padrões batem com os fatos estilizados da literatura [1] e justificam tanto o uso de inovações t -Student quanto a adoção de modelos com volatilidade variável no tempo.

Tabela 2: Estatísticas descritivas dos log-retornos diários (%) de PETR4, 2010–2026.

Estatística	Valor
N (observações)	4053
Média	0,0447
Mediana	0,0662
Desvio-padrão	2,7351
Mínimo	$-35,2367$
Máximo	20,0671
Assimetria	$-0,9272$
Curtose (excesso)	13,3484

4.2 Visualização da série

A Figura 1 mostra a série de preços e dos log-retornos com os eventos modelados destacados por linhas tracejadas. No painel superior, fica visível a forte queda do preço entre 2014 e 2016 — período do desenrolar da Operação Lava Jato e do ciclo de baixa do

³Calculada como $\sigma_{\text{anual}} = \sigma_{\text{diária}} \cdot \sqrt{252} \approx 2,74 \cdot 15,87$.

petróleo. No painel inferior, percebem-se nitidamente os clusters de volatilidade. Chamam atenção o período da pandemia da COVID-19 em março de 2020, quando se registrou o retorno mínimo da amostra ($-35,24\%$), e o salto negativo associado à demissão de Castello Branco em fevereiro de 2021.




Figura 1: PETR4: preço de fechamento ajustado (acima) e log-retornos diários em % (abaixo). As linhas tracejadas vermelhas indicam os eventos modelados.

4.3 Distribuição dos retornos

A Figura 2 compara o histograma dos retornos com a densidade da distribuição normal de mesma média e variância e apresenta o QQ-plot contra a normal. Os dois gráficos rejeitam, na prática, a hipótese de normalidade. O pico empírico em torno de zero é bem mais alto que o previsto pela normal teórica, e há massa de probabilidade nas caudas que a curva vermelha não consegue acomodar. No QQ-plot, os pontos extremos se afastam visivelmente da reta de referência, sobretudo na cauda inferior, onde aparecem retornos abaixo de -30% que estariam praticamente excluídos sob normalidade. Esses padrões reforçam a necessidade de modelar as inovações por uma distribuição com caudas pesadas.




Figura 2: Histograma com densidade normal teórica sobreposta (esquerda) e QQ-plot contra a normal (direita).

4.4 Testes de hipótese

A Tabela 3 consolida os testes estatísticos aplicados. O teste de Jarque-Bera rejeita fortemente a normalidade, com estatística superior a 30 mil. Os testes ADF e KPSS, aplicados de forma confirmatória, indicam estacionariedade dos log-retornos. O ADF rejeita a presença de raiz unitária com p -valor virtualmente nulo, enquanto o KPSS não rejeita a hipótese nula de estacionariedade ao nível de 5%, com p -valor de 0,0783 — valor próximo do limite, o que merece atenção e foi um dos motivos para considerar quebras estruturais via análise de intervenção. O teste ARCH-LM com 10 defasagens rejeita de forma esmagadora a homocedasticidade, com p -valor da ordem de 10^{-136} , justificando a adoção de modelos da família GARCH.

Tabela 3: Testes estatísticos aplicados aos log-retornos.

Teste	Estatística	p -valor	Conclusão
Jarque-Bera	30589,85	≈ 0	Rejeita normalidade
ADF (raiz unitária)	-22,1476	≈ 0	Série estacionária
KPSS	0,3973	0,0783	Não rejeita estacionariedade
ARCH-LM(10)	663,42	≈ 0	Forte heterocedasticidade

4.5 Funções de autocorrelação

A Figura 3 apresenta as ACFs dos retornos e dos retornos ao quadrado. A primeira é praticamente compatível com ruído branco, com defasagens isoladas atingindo as bandas de confiança, sem padrão sistemático. A segunda exibe autocorrelações persistentes e significativas até defasagens elevadas. Esse contraste é a assinatura clássica do efeito

ARCH e dá suporte adicional à modelagem da variância condicional.




Figura 3: ACF dos log-retornos (acima) e dos log-retornos ao quadrado (abaixo).

5 Construção do Modelo ARMA-GARCH

5.1 Modelos candidatos e seleção

Estimei, por máxima verossimilhança e com inovação t -Student padronizada, três modelos. O primeiro, M1, é um $AR(1)$ -GARCH(1,1)- t , especificação básica que serve de referência. O segundo, M2, é um $AR(1)$ -EGARCH(1,1)- t , que adiciona termo de assimetria à dinâmica da variância. O terceiro, M3, é um $ARX(1)$ -EGARCH(1,1)- t que inclui na média os três regressores de intervenção descritos na Seção 3.

A primeira tentativa, ainda na fase exploratória, foi um $AR(1)$ -GARCH(1,1) com inovação normal. Os diagnósticos rejeitaram fortemente a normalidade dos resíduos padronizados e isso me levou a adotar a t -Student como distribuição padrão para todos os modelos comparados aqui. A Tabela 4 compara os três modelos finais por log-verossimilhança, AIC e BIC.

Tabela 4: Comparação dos modelos estimados.

Modelo	Log-Lik	AIC	BIC
GARCH(1,1)- t	-9058,18	18128,37	18166,21
EGARCH(1,1)- t	-9040,92	18095,84	18139,99
EGARCH(1,1)- t + Interv.	-9036,17	18092,34	18155,41

O modelo M3 teve o menor AIC e a maior log-verossimilhança — foi o escolhido como modelo final. A redução de AIC do M1 para o M2, de 32,5 unidades, sugere fortemente efeito alavancagem na série, e o ganho adicional do M2 para o M3, de 3,5 unidades, mostra a relevância das intervenções. O BIC, mais parcimonioso, classifica o EGARCH simples ligeiramente à frente, mas optei pelo M3 por causa da elevada significância estatística dos coeficientes de intervenção, apresentada a seguir.

5.2 Estimativas do modelo final

A Tabela 5 traz os coeficientes estimados, erros-padrão robustos, estatísticas t e p -valores do modelo final.

Tabela 5: Coeficientes estimados do modelo final EGARCH(1,1)- t com intervenções.

Parâmetro	Coef.	EP	t	p -valor
<i>Equação da média</i>				
Constante	0,0456	0,0483	0,945	0,345
AR(1)	-0,0316	0,0250	-1,261	0,207
I_{Castello} (pulso)	-6,4969	0,665	-9,776	$1,42 \times 10^{-22}$
I_{Lula} (degrau)	0,0715	0,0654	1,092	0,275
I_{Prates} (pulso)	-2,0602	0,221	-9,312	$1,25 \times 10^{-20}$
<i>Equação da volatilidade</i>				
ω	0,0282	0,00770	3,664	$2,48 \times 10^{-4}$
α	0,1389	0,0188	7,381	$1,58 \times 10^{-13}$
γ	-0,0301	0,00900	-3,340	$8,37 \times 10^{-4}$
β	0,9888	0,00365	271,06	$< 10^{-300}$
<i>Distribuição</i>				
ν	4,9073	0,406	12,092	$1,16 \times 10^{-33}$

Vale olhar os parâmetros com calma. O $\beta = 0,989$ mostra volatilidade muito persistente: choques na variância demoram a se dissipar, o que é típico de ações alavancadas em mercados emergentes. O $\alpha = 0,139$, significativo, mede a sensibilidade da variância aos choques recentes em valor absoluto. O $\gamma = -0,030$, com p -valor inferior a 0,001, confirma o efeito alavancagem antes inferido pela queda de AIC: choques negativos elevam $\ln \sigma_t^2$ em maior magnitude que choques positivos de mesma intensidade, o que concorda com

a literatura empírica em finanças [1]. Por fim, a estimativa de $\nu = 4,91$ graus de liberdade é bastante baixa e indica caudas extremamente pesadas. Note-se que para $\nu < 5$ os momentos de ordem superior à quarta nem existem na distribuição teórica.

6 Análise de Intervenção

A demissão de Roberto Castello Branco, anunciada em 19/02/2021, gerou o maior efeito de intervenção identificado. O coeficiente do pulso correspondente foi estimado em $-6,50$ pontos percentuais, com p -valor da ordem de 10^{-22} , indicando queda atípica do log-retorno do dia mesmo após controlar por toda a estrutura ARMA-EGARCH. O resultado reflete a percepção do mercado quanto ao risco de interferência política sobre a empresa — percepção que se traduziu em forte revisão imediata dos preços.

Já a mudança da política de preços de combustíveis, anunciada em 08/03/2023 sob o governo Lula, foi modelada por dummy do tipo degrau. O coeficiente estimado, de $0,072$ ponto percentual ao dia, não foi significativo ($p = 0,275$). Isso sugere que, controlando-se pelos demais fatores do modelo, não houve alteração persistente do nível médio dos retornos após a mudança formal da política. Uma interpretação plausível é que parte relevante do impacto havia sido absorvida nos meses anteriores, à medida que a nova diretriz foi sendo sinalizada — comportamento compatível com a hipótese de mercados eficientes na forma semiforte.

A demissão de Jean Paul Prates, em 14/05/2024, também resultou em coeficiente altamente significativo, com queda estimada de $2,06$ pontos percentuais no log-retorno do dia ($p \approx 10^{-20}$), porém de magnitude menor que o evento de 2021. A diferença pode ser atribuída à maior antecipação do mercado, dado que rumores sobre a saída do executivo precediam o anúncio formal.

7 Diagnóstico do Modelo

7.1 Análise gráfica dos resíduos

A Figura 4 traz o painel de diagnóstico dos resíduos padronizados do modelo final. O gráfico de série temporal dos resíduos não revela padrões sistemáticos remanescentes, e suas funções de autocorrelação — tanto sobre os próprios resíduos quanto sobre seus quadrados — ficam, em geral, dentro das bandas de confiança. O QQ-plot contra a t -Student com $\nu = 4,91$ apresenta bom alinhamento, exceto em poucos pontos extremos da cauda inferior, principalmente associados à pandemia da COVID-19. No conjunto, os

gráficos indicam que o modelo se ajusta bem aos dados.




Figura 4: Painel de diagnóstico do modelo final: resíduos padronizados, suas ACFs e QQ-plot contra a t -Student.

7.2 Volatilidade condicional

A Figura 5 exibe a volatilidade condicional estimada. Os picos coincidem com episódios bem documentados: o ciclo da Operação Lava Jato e do choque do petróleo entre 2014 e 2016, a pandemia da COVID-19 em março de 2020, a turbulência associada à demissão de Castello Branco em fevereiro de 2021 e os movimentos relacionados às mudanças de comando e política regulatória da estatal nos anos posteriores. A persistência elevada captada pelo coeficiente β é visível na lentidão com que as elevações de volatilidade voltam aos níveis médios.




Figura 5: Volatilidade condicional estimada pelo modelo EGARCH(1,1)- t com intervenções.

8 Estimação do Value-at-Risk e Backtesting

A partir do modelo final, calculei os limites diários de Value-at-Risk nos níveis de 95% e 99%, segundo

$$\text{VaR}_t(\alpha) = -(\hat{\mu}_t + q_\alpha(\nu) \hat{\sigma}_t),$$

onde $q_\alpha(\nu)$ é o quantil- α da t -Student padronizada com $\nu = 4,91$ graus de liberdade. A Tabela 6 resume o resultado do backtesting nos dois níveis.

Tabela 6: Resultados do backtesting do VaR.

Nível	Violações	Taxa obs.	Taxa esp.	Kupiec LR	p -valor
95%	197	4,86%	5,00%	0,170	0,680
99%	45	1,11%	1,00%	0,481	0,488

No nível de 95%, a taxa observada de violações (4,86%) está muito próxima da nominal, com desvio inferior a 0,15 ponto percentual em uma amostra de 4053 dias, e o teste de Kupiec não rejeita cobertura correta. No nível de 99%, o teste também não rejeita (LR = 0,481, $p = 0,488$), o que valida o modelo para gestão de risco de mercado em padrões compatíveis com os Acordos de Basileia. A Figura 6 mostra os limites de $-\text{VaR}$ sobrepostos aos retornos observados, com as violações do nível de 99% destacadas em vermelho.




Figura 6: Retornos diários, limites $-VaR$ a 95% e 99% e violações do VaR 99%.

9 Discussão Crítica

O modelo final tem virtudes importantes do ponto de vista estatístico e prático. O EGARCH com inovações t -Student capturou ao mesmo tempo clusters de volatilidade, leptocurtose e efeito alavancagem — os principais fatos estilizados das séries financeiras. Todos os parâmetros têm interpretação econômica clara, o que dá transparência ao modelo e o torna defensável em contextos regulatórios. A inferência se baseou em erros-padrão robustos, e o backtesting empregou um teste com distribuição assintótica conhecida, permitindo decisões formais sobre adequação. O resultado positivo no teste de Kupiec a 99% reforça a aplicabilidade prática.

Há limitações que vale comentar. O EGARCH suaviza a representação de saltos discretos de grande magnitude — e a amostra tem um caso emblemático: o pico da pandemia, com retorno mínimo de $-35,24\%$. Modelos com componente de saltos, como o Jump-GARCH ou variantes com inovações de mistura, capturariam melhor esses extremos.

O coeficiente $\beta = 0,989$ está colado na fronteira de não-estacionariedade da variância, o que pode indicar quebras estruturais não totalmente capturadas pelas três intervenções modeladas. Modelos com mudança de regime markoviana, como o Markov-Switching GARCH, seriam uma alternativa direta [3].

Além disso, a constante e o coeficiente $AR(1)$ na equação da média não foram significativos. O resultado é coerente com a hipótese de mercados eficientes na forma fraca, mas indica baixo poder preditivo do componente de média — algo importante de explicitar para quem fosse usar o modelo para previsão e não apenas para risco. Por fim, o teste de Kupiec verifica apenas cobertura incondicional do VaR ; um exame complementar de in-

dependência das violações ao longo do tempo (teste de Christoffersen) seria recomendável e fica como melhoria evidente para uma versão futura.

A coleta de dados também tem três pontos sensíveis. Primeiro, os preços de fechamento ignoram a dinâmica intraday, na qual frequentemente se concentram os picos de volatilidade durante anúncios e divulgações de resultados — medidas baseadas em volatilidade realizada com dados de alta frequência seriam preferíveis. Segundo, ainda que o Yahoo Finance ajuste os preços retroativamente para proventos e desdobramentos, podem ficar descontinuidades em torno de eventos relevantes, sobretudo em datas ex-dividendo de grandes pagamentos. Terceiro, a presença dos retornos extremos da pandemia tende a dominar a estimação dos parâmetros e poderia ser tratada de forma específica, seja por marcação como observações influentes, seja por modelagem de regime distinto.

Como caminhos para extensões futuras, destaco: incluir regressores macroeconômicos exógenos — preço do petróleo Brent, taxa de câmbio, taxa Selic — na equação da média ou da variância; modelagem multivariada com ações correlacionadas (VALE3, ITUB4) via DCC-GARCH [3]; teoria de valores extremos para estimar a cauda do VaR em níveis mais conservadores como 99,5% ou 99,9%; modelos de volatilidade realizada com dados intraday; e estimação em janelas móveis para avaliar a estabilidade dos parâmetros ao longo do período amostral.

10 Conclusão

Apliquei a metodologia ARMA-GARCH à modelagem de retornos da PETR4 entre 2010 e 2026. Os resultados confirmam todos os fatos estilizados clássicos das séries financeiras: estacionariedade dos retornos, leptocurtose extrema, autocorrelação dos retornos ao quadrado e efeito alavancagem. O modelo final, EGARCH(1,1)- t com regressores de intervenção, passou nos diagnósticos formais e no backtesting de VaR a 99% pelo teste de Kupiec, com aderência adequada aos dados e potencial uso para gestão de risco de mercado.

A análise de intervenção mostrou que dois dos três eventos modelados — as demissões de CEOs em 2021 e 2024 — tiveram impactos negativos altamente significativos nos retornos do dia do anúncio. Já a mudança de política de preços de março de 2023 não apresentou efeito permanente estatisticamente detectável, resultado consistente com a hipótese de antecipação do mercado.

As limitações apontadas e as melhorias sugeridas, sobretudo a incorporação de variáveis exógenas e a modelagem multivariada, são caminhos diretos para a continuidade desta linha de pesquisa.

Referências

- [1] MORETTIN, P. A. *Econometria Financeira: Um Curso em Séries Temporais Financeiras*. 3. ed. São Paulo: Edgard Blücher, 2017. ISBN: 978-85-212-1233-1.
- [2] MORETTIN, P. A.; TOLOI, C. M. C. *Análise de Séries Temporais, Volume 1: Modelos Lineares Univariados*. 3. ed. São Paulo: Edgard Blücher (ABE – Projeto Fisher), 2018. ISBN: 978-85-212-1888-3.
- [3] MORETTIN, P. A.; TOLOI, C. M. C. *Análise de Séries Temporais, Volume 2: Modelos Multivariados e Não-Lineares*. São Paulo: Edgard Blücher (ABE – Projeto Fisher), 2020. ISBN: 978-65-5506-029-0.
- [4] SHUMWAY, R. H.; STOFFER, D. S. *Time Series Analysis and Its Applications: With R Examples*. 4. ed. New York: Springer, 2017. ISBN: 978-3-319-52451-1.
- [5] ENGLE, R. F. Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. *Econometrica*, v. 50, n. 4, p. 987–1007, 1982. ISSN: 0012-9682.
- [6] BOLLERSLEV, T. Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, v. 31, n. 3, p. 307–327, 1986. ISSN: 0304-4076.
- [7] NELSON, D. B. Conditional heteroskedasticity in asset returns: a new approach. *Econometrica*, v. 59, n. 2, p. 347–370, 1991. ISSN: 0012-9682.
- [8] SHEPPARD, K. *arch: Autoregressive Conditional Heteroskedasticity (ARCH) and other tools for financial econometrics, written in Python*. Documentação do pacote, 2024. Disponível em: <https://bashtage.github.io/arch/>.